

## بهینه‌سازی، فشرده‌سازی و تحلیل امنیت مدل‌های یادگیری عمیق

مدل هدف: MobileNetV2

دیتاست‌ها:

۱. CIFAR-10 (تصاویر  $32 \times 32$  پیکسل - رزولوشن پایین)

۲. STL-10 (تصاویر  $96 \times 96$  پیکسل - رزولوشن بالا)

### هدف پروژه

هدف این پروژه، پیاده‌سازی و مقایسه‌ی جامع تکنیک‌های آموزش (Training)، فشرده‌سازی (Compression) و استقرار (Deployment) مدل‌های عصبی است. دانشجویان موظف‌اند یک پایپ‌لاین کامل را روی دو دیتاست با کیفیت‌های متفاوت اجرا کرده و نتایج را تحلیل کنند.

### بخش اول: استراتژی‌های آموزش

در این فاز باید مدل MobileNetV2 را با رویکردهای زیر آموزش دهید و دقت نهایی را ثبت کنید:

#### ۱. تنظیم جزئی (Partial Fine-Tuning) - اجباری

- روش: بارگذاری وزن‌های ImageNet، فریز کردن تمام لایه‌های استخراج ویژگی و آموزش تنها لایه طبقه‌بند (Classifier).

- هدف: ایجاد خط مبنا (Baseline) برای سنجش سرعت همگرایی.

#### ۲. تنظیم دقیق کامل (Full Fine-Tuning) - اجباری

- روش: آنفریز کردن کل شبکه پس از آموزش اولیه و آموزش مجدد تمام لایه‌ها با نرخ یادگیری بسیار پایین ( $1e-5$ ).

- هدف: دستیابی به بالاترین دقت ممکن (Standard Baseline).

### ۳. تقطیر دانش (Knowledge Distillation) – امتیازی (Bonus)

- توضیح: انتقال دانش از یک مدل بزرگ (Teacher) به مدل کوچک (Student).
- روش: استفاده از روش هینتون (Hinton's Response-Based Knowledge Distillation).
  - معلم: ResNet-50.
  - دانش‌آموز: MobileNetV2 (با مقداردهی تصادفی).
  - تابع هزینه (Loss): ترکیبی از CrossEntropy (برای لیبل‌های واقعی) و KL-Divergence (برای نزدیک کردن توزیع احتمال خروجی دانش‌آموز به معلم با پارامتر  $T$ ).

### بخش دوم: جراحی و بهینه‌سازی ساختاری (Structural Optimization)

روی مدل Full Fine-Tuned (و مدل Distilled در صورت انجام)، موارد زیر را اجرا کنید:

#### ۱. تفسیرپذیری (Grad-CAM) – اجباری

- استخراج نقشه‌های حرارتی (Heatmaps) روی تصاویر تست.
- تحلیل: بررسی اثر رزولوشن تصویر (CIFAR vs STL) بر روی قابلیت تفسیرپذیری مدل.

#### ۲. هرس کردن (Pruning) – اجباری

- Iterative Unstructured: حذف ۲۰٪ وزن‌ها و بازآموزی (در ۳ مرحله).
- Structured: حذف ۴۰٪ کانال‌های خروجی در لایه آخر.

#### ۳. فرضیه بلیت بخت‌آزمایی (Lottery Ticket Hypothesis - LTH) – امتیازی (Bonus)

- **توضیح:** این فرضیه بیان می کند که در شبکه های عصبی متراکم، زیرشبکه هایی (Sub-networks) وجود دارند که اگر با همان وزن های اولیه (Initialization Weights) آموزش ببینند، به دقتی معادل مدل اصلی می رسند.

#### • تسک:

۱. ماسک هرس (Pruning Mask) مدل آموزش دیده را استخراج کنید.
۲. وزن های مدل را دقیقاً به مقادیر لحظه شروع (قبل از آموزش) بازگردانید (Rewind).
۳. ماسک را اعمال کرده و مدل تنک (Sparse) را مجدداً آموزش دهید. آیا مدل به دقت قبلی می رسد؟

#### ۴. تجزیه ماتریس (Low-Rank Factorization / SVD) – امتیازی (Bonus)

- **توضیح:** ماتریس وزن لایه های کاملاً متصل (fully connected) ( $W \in R^{m \times n}$ ) دارای افزونگی اطلاعاتی هستند. با استفاده از **تجزیه مقادیر منفرد (SVD)**، می توان این ماتریس را به ضرب دو ماتریس کوچکتر ( $U \in R^{m \times k}$  و  $V \in R^{k \times n}$ ) تقریب زد که  $k \ll m, n$ .
- **تسک:** لایه آخر (Classifier) مدل را با SVD تجزیه کرده و مدل را مجدداً (Fine-Tune) کنید تا افت دقت جبران شود. تاثیر آن بر حجم مدل را گزارش دهید.

#### بخش سوم: تست استقرار و امنیت (Security & Deployment)

##### ۱. کوانتیزه سازی (Quantization) – اجباری

- **روش:** تبدیل مدل ها به فرمت Int8 با استفاده از روش **Post-Training Quantization (FX Graph Mode)**.
- **تحلیل:** مقایسه میزان افت دقت در مدل "Full Fine-Tuned" نسبت به مدل "Distilled". (کدام مدل پایدارتر است؟)

## ۲. پایداری (Robustness) – اجباری

- ارزیابی دقت مدل روی تصاویر تخریب شده با نویز گاوسی (Gaussian Blur).

## ۳. حمله خصمانه (Adversarial Attack - FGSM) – امتیازی (Bonus)

- توضیح: روش FGSM (Fast Gradient Sign Method) با محاسبه گرادیان تابع هزینه نسبت به پیکسل‌های ورودی، نویزهای نامرئی اما جهت‌داری را به تصویر اضافه می‌کند که باعث خطای مدل می‌شود.
- تسک: پیاده‌سازی حمله با  $\epsilon=0.05$  و مقایسه مقاومت مدل‌های مختلف.

## ۴. خروجی نهایی – اجباری

- تبدیل مدل نهایی به فرمت ONNX.

## ۵. خروجی مورد انتظار

یک گزارش نهایی شامل جدول مقایسه‌ای زیر برای هر دو دیتاست:

روش	دقت پایه	دقت بعد از هرس	دقت کوانتیزه (Int8)	دقت در حمله FGSM
Partial Tuning	...	–	...	–
Full Fine-Tuning	...	...	...	...
Distillation (Bonus)	...	...	...	...

